

使用 dockerHDDM 对决策偏差进行建模

邬思宇¹, 潘晚珂^{1*}, 胡传鹏¹

(南京师范大学心理学院, 南京, 210024;

*通讯作者: 胡传鹏, hcp4715@hotmail.com; 潘晚珂, panwanke2023@gmail.com)

摘要 在二项迫选决策任务中, 人们可能存在决策偏差, 即对某一选项产生的系统性趋近或回避的倾向。从认知过程的角度来看, 决策偏差可源于决策前的初始偏好, 也可源于证据积累过程中的系统性偏向, 但传统行为数据分析难以实现这一区分。漂移扩散模型 (DDM) 为分离两类偏差提供了理论框架, 但准确建模决策偏差依赖于建模方式与研究问题的匹配, 不同偏差类型对应不同的参数设定与模型选择。HDDM 工具包不仅提供了灵活建模决策偏差的多样化功能, 还通过规范化接口实现了数据结构与建模流程的标准化。本文基于 dockerHDDM 工具, 系统介绍了决策偏差的建模方法: 首先阐述 DDM 框架下的两类决策偏差; 然后详细说明 HDDM 中准确性编码与选择编码的差异、参数翻转的核心原理以及漂移准则 (dc) 的实现方式, 并提供完整的代码示例; 最后通过模拟数据和实证数据, 系统比较了 9 种建模组合对两类偏差的适配性。结果表明, 不同偏差对应不同建模方式, 起始点偏差可通过选择编码或结合参数翻转准确恢复, 而漂移偏差必须直接拟合 dc 参数才能实现无偏估计。本文为建模决策偏差提供了从原理到实践的系统指南, 涵盖原理介绍, 参数设定, 模型选择与结果解读。

关键词 决策偏差, 起始点偏差, 漂移偏差, 漂移扩散模型, dockerHDDM

Modeling decision bias in dockerHDDM: A complete tutorial

Siyu Wu¹, Wanke Pan¹, Hu Chuan-Peng¹

(¹School of Psychology, Nanjing Normal University, Nanjing, Jiangsu, China)

Abstract: In two-alternative forced-choice (TAFC) tasks, decision bias is a systematic tendency to approach or avoid a particular option. From a cognitive process perspective, decision bias can originate from pre-decision initial bias or from bias during evidence accumulation. Traditional behavioral data analysis cannot reliably distinguish between the two sources. The drift-diffusion model (DDM) provides a theoretical framework to separate them, but accurate modeling depends on matching the modeling approach to the

research question: different types of bias require different parameterizations and model specifications. The HDDM toolbox not only offers flexible functions for modeling decision biases but also standardizes data structures and modeling workflows through a unified interface. Based on dockerHDDM, this tutorial systematically introduces methods for modeling decision bias. We first describe the two types of decision bias within the DDM framework and then explain in detail the difference between accuracy coding and choice coding in HDDM, the core principle of parameter flipping, and the implementation of the drift criterion (dc), with complete code examples. Finally, using simulated and empirical data, we systematically compare the suitability of nine modeling combinations for the two types of bias. The results indicate that different biases align with different modeling approaches: starting point bias can be modeled by choice coding or parameter flipping with accuracy coding, whereas drift bias must be estimated via the parameter dc . This tutorial provides a systematic guide from theory to practice for modeling decision biases, covering theoretical foundations, parameter settings, model selection, and result interpretation.

Keywords: decision bias, starting point bias, drift bias, drift-diffusion model, dockerHDDM

1 引言

在二项迫选的决策任务中，决策偏差（decision bias）通常表现为个体对某一选项产生的系统性趋近或回避的倾向(Leite & Ratcliff, 2011)。决策偏差长期在认知心理学、社会心理学和精神疾病等领域受到广泛关注。例如，与健康对照组相比，抑郁症患者不仅表现出奖赏反应性减弱(Cléry-Melin et al., 2019; Eshel & Roiser, 2010; Horne et al., 2021)，还对负性信息存在系统性偏向(Gotlib & Joormann, 2010; Huys et al., 2015)。决策偏差源于两类不同的认知机制：其一为预期或先验信念所诱发的反应前初始偏向；其二为在不同刺激或选项条件下信息加工方式的系统性偏差(Mulder et al., 2023; Ratcliff et al., 2016; Urai et al., 2019; van Ravenzwaaij et al., 2012; White et al., 2017)。两类偏差在认知加工层面的本质差异，提示它们可能具有不同的神经机制(Mulder et al, 2012)，并对区分精神疾病中不同类型的加工异常具有重要理论意义(Lloyd et al., 2024; Scholz et al., 2020)。然而，传统行为数据分析依赖反应时间和选择，难以确切区分上述两种机制在行为偏差中的具体贡献。

漂移扩散模型（drift-diffusion model, DDM; Ratcliff et al., 2016）作为一种基于决策过程的计算模

型，为解决这一问题提供了有效工具。DDM 假定人类的决策过程遵循证据积累机制(刘逸康，胡传鹏, 2024)，证据从起始点开始积累，每个选项对应一个边界，一旦证据超过边界，便会做出相应决策。模型的核心决策参数包括：决策阈值 (threshold, a)，漂移率 (drift rate, v) 以及证据积累的起始点 (starting point, z)。在 DDM 框架中，上述两种决策偏差的认知机制表现在不同模型参数上：一是起始点偏差 (starting point bias)，表现为证据积累的初始位置向某一边界偏移，相当于在证据积累开始前就倾向于选择某一选项(Liebman, 2020; Mulder et al., 2023; Ratcliff et al., 2004; Tomkins et al., 2025)；二是漂移偏差 (drift bias)，表现为对不同选项的证据积累速率出现系统性不对称(Ratcliff & McKoon, 2008; Ratcliff et al., 2016)，这一偏差可由漂移准则 (drift criterion, dc) 定义(Leong et al., 2019; Mulder et al., 2023; Sánchez-Fuenzalida et al., 2023; van Ravenzwaaij et al., 2012)，本质是个体在证据积累过程中，存在将信息解读为支持某一特定选项的恒定倾向。

然而，准确建模这两类偏差依赖于建模方式与研究问题的匹配。例如，White 等人(2014)系统探讨了起始点偏差与漂移偏差的本质区别，通过构建针对偏差效应的 DDM 模型，他们证实两类偏差可被独立诱发；Urai 等人(2019)在涵盖多感官模态、多任务范式的系列实验中，通过条件偏差函数、多模型比较等方法，成功揭示了驱动个体选择重复行为的机制是漂移偏差而非起始点偏差。但上述研究对决策偏差的操作性定义不尽相同，实验范式与设置亦存在差异，建模方案也高度自定义化。最近 Cerracchio 等(2023)综述系统梳理了决策偏差的常用建模方法，指出注意操纵通常影响漂移率，而刺激的比例则主要影响起始点。然而，既往研究在关键方法论细节上仍缺乏系统梳理，特别是尚未厘清“实验操纵—数据特征—建模策略”之间的关系：即不同类型的决策偏差应如何通过实验任务进行诱发？这些操纵如何表征于数据结构与行为分布之中？以及如何依据上述特征选择最优的建模路径？

既往研究多依赖自定义工具或研究者自行编写的函数实现决策偏差建模，缺乏统一的规范与标准。基于 Python 的分层漂移扩散模型工具包 (Hierarchical Drift Diffusion Model, HDDM; Wiecki et al., 2013) 在一定程度上弥补了这一不足：作为目前应用最为广泛的 DDM 分析实现工具之一，HDDM 不仅提供了灵活建模决策偏差的多样化功能，还通过规范化接口实现了数据结构与建模流程的标准化。在此基础上，本文基于 dockerHDDM (Pan et al., 2025)，旨在为研究者提供规范和系统的决策偏差建模方案及可操作的方法指导。针对上述问题，本教程将从以下三个层面展开：(1) 系统梳理 DDM 框架下的两类决策偏差；(2) 随后详细介绍 HDDM 中两种基础编码方式的差异，阐述参数翻转的核心原理与实施方法，以及如何在参数翻转的基础上引入 dc 参数建模漂移偏差，并提供对应的代码

实现示例；(3) 最后结合模拟数据与实证数据分析，展示不同决策偏差的最优建模方案，验证方法的有效性 with 合理性。

2 DDM 框架下的两类决策偏差

2.1 DDM 理论基础

漂移扩散模型 (DDM) 假设，决策是一个从起始点开始，对证据进行连续积累直至到达某个反应边界的过程。具体而言，模型包含以下四个核心参数(Boag et al., 2025; Voss et al., 2013)：决策阈值 (a) 为两个边界的距离，表示做出决策前需要积累的证据总量。较宽的边界意味着需要更多的证据，决策更为谨慎但速度较慢；较窄的边界则会加快决策但更容易受噪声影响，可以体现速度-准确性权衡。起始点 (z) 位于这两个边界之间（通常位于正中央），表示做出不同决策所需证据量的相对差异，可用于反映个体的先验偏向。漂移率 (v) 表示证据积累的平均速率，其方向和大小决定了信息向哪个边界积累以及积累的快慢， v 大于 0 表示向上边界积累，小于 0 则表示向下边界积累。非决策时间 (non-decision time, t) 涵盖了除决策过程之外其余的认知过程，包含刺激编码和运动反应执行。DDM 将决策过程分解为不同的认知成分，为理解决策偏差的来源提供了理论框架：偏差既可源于决策前就已存在的偏好，也可源于决策过程中证据积累方式的系统性改变。

2.2 DDM 中的偏差建模

在 DDM 框架下，偏差主要通过两种方式产生：一是通过将累积起始点向某一边界偏移；二是通过选择性地改变针对某一选项相对于另一选项的证据累积速率。两种建模方式对应两类决策偏差。

起始点偏差反映个体在证据积累开始前就已存在的先验偏好。实验中常通过操纵刺激出现概率、选项奖励或先验信息来诱导此类偏差(Ashby, 1983; Bogacz et al., 2006; Diederich & Busemeyer, 2006; Simen et al., 2009; van Ravenzwaaij et al., 2012; White & Poldrack, 2014; White et al., 2010)。以随机点运动任务为例，被试需要判断随机运动的点阵整体是向左还是向右运动。使用 DDM 对随机点运动任务数据进行建模时，设定上边界代表选项左，下边界代表选项右，在无偏条件下，起始点位于边界正中，即 $z = a / 2$ 。如果实验中向左运动的试次占总试次的 80%，向右运动的试次占总试次的 20%，被试可能会习得这种比例不对称性，在证据积累开始前就倾向于选择向左运动，反映在 DDM 中，即为 $z > a / 2$ 表示偏向上边界对应的选项左。起始点偏差主要影响决策过程的早期阶段，集中

在较快反应试次中。随着决策时间的延长，积累的证据逐渐占据主导地位，起始点偏差的影响会逐渐减弱。

与起始点不同，漂移偏差则是个体在证据积累过程中出现的系统性偏移。实验中可通过调整决策标准(Leite & Ratcliff, 2011; van Ravenzwaaij et al., 2012; White & Poldrack, 2014)或操纵动机(Leong et al., 2019)来诱发。例如，Leong 等人(2019)在面孔/场景分类任务中，被试需要在面孔和场景中进行选择（判断哪一个占比更高）。使用 DDM 对该数据进行建模时，模型的上边界代表人脸，下边界代表场景。实验中通过操纵合作与竞争情境，使被试产生对特定刺激的期待（如面孔），这种动机产生的加工偏好会持续作用于证据积累的过程。HDDM 中对漂移偏差的建模是通过在证据积累中引入一个与当前刺激类型（面孔或场景）无关的常数项来体现。这一常数项被称作漂移准则 (dc)，可看作个体在证据整合过程中将信息解读为支持某一特定选项的恒定倾向。当 dc 大于 0 时，无论当前呈现的是何种刺激，证据积累过程都会恒定地偏向上边界对应的面孔；反之，则偏向下边界对应的场景。由于 dc 作为一个常数项被持续累加到证据积累的每一步中，它对决策变量的影响会随着决策时间的延长而线性增长。因此，漂移偏差对较快和较慢反应均会产生影响。

3 基于 HDDM 的决策偏差建模

基于 Python 的 HDDM 工具包(Wiecki et al., 2013)采用分层贝叶斯框架，可同时建模个体与群体差异，能更准确地估计参数。HDDM 中的内置模块（HDDMStimCoding、HDDMRegressor）能直接拟合 dc ，而其他工具大多依赖自行定义模型等操作，较为复杂，且缺乏系统性和规范性。本文基于 dockerHDDM 环境(Pan et al., 2025)，介绍如何通过 HDDM 建模两类决策偏差。

3.1 基础编码方式

将数据拟合到模型需要将被试的反应（response）通过 1/0 编码映射到模型的上下边界。针对不同类型的数据，HDDM 提供了两种基础的编码方式：准确性编码(accuracy coding)和选择编码(choice coding)，且默认数据格式为准确性编码，即 response 为 1 代表正确，0 代表错误。若将 response 编码为具体选项（1 代表选项 A，0 代表选项 B），则变为选择编码。表 1 展示了准确性编码方式下 HDDM 所需的示例数据列。

表 1 HDDM 所需的数据列

subj_idx	rt	response	accuracy	choice	stim
0	0.73		0	0	1
0	0.47		1	0	0
0	0.51		1	0	0
0	0.57		1	1	1
0	0.47		1	0	0
...	...		...	...	...

注：accuracy 列表示选择是否正确（1 = 正确，0 = 错误）。choice 列记录具体选择（1 = 选项 A，0 = 选项 B）。当选择与刺激一致时，accuracy 为 1，否则为 0。在模型指定的输入数据中，必须包含名为'response'的列；若采用准确性编码，该列应填入表示对错的数值（如原有数据中的'accuracy'值）；若采用选择编码，该列则填入具体选项的数值（如'choice'值）。

准确性编码下，response 对应正确或错误。漂移率 ν 大于 0 表示证据向正确选项积累，小于 0 表示向错误选项积累。 ν 反映在给定实验条件下整体的证据积累速率；若正确率接近 50%，则 ν 趋近于 0。

选择编码下，response 对应选项 A 和选项 B。起始点 z 大于 0.5 表明存在偏向选项 A（上边界）的偏差，小于 0.5 则偏向选项 B（下边界）。漂移率 ν 大于 0 代表向选项 A 积累的速率，小于 0 代表向选项 B 积累的速率。在此编码下， ν 反映两个选项间证据积累的平衡状态，且受被试选择各选项比例的影响。若选择 A 与 B 的频次相近，则 ν 趋近于 0。

两种编码各有优势，但也存在相应局限。准确性编码可直接量化朝向正确选项的整体证据积累速率，但无法对起始点偏差进行建模，因为在这种编码模式下起始点 z 代表偏向正确/错误的选择，不具备实际心理意义。选择编码能有效捕捉朝向某一选项的起始点偏差，但其漂移率反映的是朝向所选选项（同时包括正确和错误选择试次的的数据）的证据平衡状态，无法纯粹表征朝向某个选项且正确反应的证据积累速率。此外，这两种基础编码方式均无法直接对两个选项的漂移偏差（对应 dc

参数) 进行建模。

3.2 参数翻转

为解决单一编码无法同时捕捉有意义的起始点偏差与朝向正确选项的证据积累速率这一问题，HDDM 引入了参数翻转方法。通过对不同刺激类型的数据进行拆分并翻转，可使 v 始终代表朝向正确选项的证据积累速率，同时让 z 的解释能够对应特定选项（如选项 A）的偏差。

翻转操作包含两个核心步骤：一是按刺激类型（ $\text{stim} = 1$ 或 0 ）对数据进行拆分；二是对刺激为 0 条件下的参数进行翻转（即 $v' = -v$ ，或 $z' = 1 - z$ ）。数据拆分使模型能依据刺激推断被试的选择，参数翻转则实现了不同刺激条件下参数解释的统一。

在准确性编码中，上下边界分别对应正确和错误。然而，具体哪个选项是正确的，取决于当前试次呈现的刺激（例如，刺激 A 对应选择 A 正确，刺激 B 对应选择 B 正确）。这导致起始点 z 的解释随刺激变化：当刺激为 A 时（ $\text{stim} = 1$ ），上边界对应正确的选项 A，此时 z 大于 0.5 表示被试倾向于选择 A；当刺激为 B 时（ $\text{stim} = 0$ ），上边界对应正确的选项 B，此时 z 大于 0.5 表示对 B 的先验偏好，而对 A 的偏好则由 $1 - z$ （小于 0.5 ）表示。为使 z 大于 0.5 能够始终代表朝向选项 A 的偏好，需对刺激 B 条件下的 z 进行翻转，令 $z' = 1 - z$ 。翻转后，原本刺激 B 中表示偏向 A 的 z （小于 0.5 ）变为 z' （大于 0.5 ），从而与刺激 A 条件下的解释一致。这样，无论刺激类型如何， z 大于 0.5 都代表对选项 A 的先验偏向。

在选择编码中，上下边界分别对应选项 A 和选项 B。但正确反应对应的边界随刺激变化，导致漂移率 v 的解释依赖于刺激：当刺激为 A 时（ $\text{stim} = 1$ ），正确反应对应上边界（选项 A）， v 大于 0 表示证据向正确积累；当刺激为 B 时（ $\text{stim} = 0$ ），正确反应对应下边界（选项 B），此时 v 大于 0 表示证据向错误积累，而 $-v$ （小于 0 ）才表示证据向正确积累。为使 v 大于 0 始终表示向正确选项积累，需对刺激 B 条件下的 v 进行翻转，令 $v' = -v$ 。翻转后，原本刺激 B 中表示向正确选项积累的 v （小于 0 ）变为 v' （大于 0 ），从而与刺激 A 条件下的解释一致。这样，无论刺激类型如何， v 大于 0 都代表证据向正确选项的积累速率。

参数翻转本质上是对模型参数的对称变换，其目的是将不同刺激条件下估计得到的参数（ z 或 v ）映射到统一且固定的解释框架中。这一处理使估计结果能够直接、一致地反映研究中关注的行为偏差或信息加工表现。

3.3 漂移准则

在 HDDM 中，若要直接对不同选项间的证据积累偏差进行建模，需要使用 dc 参数。该参数需在已对漂移率进行翻转的模型框架下使用，其作用是在刺激驱动的证据积累基础上，增加一个恒定的偏向。具体而言，在基于 v 翻转的选择编码模型中：当刺激为 A 时， $v_{(total)} = v + dc$ ；当刺激为 B 时， $v_{(total)} = -v + dc$ 。其中， v 表示基础证据积累速率， dc 则为恒定漂移偏向。 dc 大于 0 表示存在朝向选项 A（上边界）的偏向， dc 小于 0 表示存在朝向选项 B（下边界）的偏向。

dc 的绝对值反映了偏向的强度。通过将 dc 作为独立参数纳入模型，研究者可直接检验不同实验条件或个体在漂移偏差上的差异。该方法相较于分别估计不同条件的 v 再比较差值，结果更准确有效。

3.4 HDDM 中建模偏差的代码实现

HDDM 提供了两种主要方式实现上述参数翻转与 dc 拟合：一是基于 HDDMStimCoding 的专用函数；二是基于 HDDMRegression 的通用回归框架。

3.4.1 基于 HDDMStimCoding 函数的实现

HDDMStimCoding 是 HDDM 中专门用来对不同刺激类别进行建模的模型，内置对称翻转机制。它通过 `stim_col` 指定刺激类别列，通过 `split_param` 指定需要翻转的参数（ z 或 v ，默认为 z ）。

若研究兴趣在于起始点偏差且希望同时比较不同条件下 v 的差异，可采用准确性编码并翻转 z ：

```
Python
# 数据编码（准确性编码）
data['response'] = data['acc']

# 构建模型
hddmStim_zflip = hddm.HDDMStimCoding(
    data,
    stim_col = 'stim',
    split_param = 'z',
    include = ['v', 'a', 't', 'z'],
    depends_on = {'z': ['condition'], 'v': ['condition']},
    bias = True
```


)

或采用选择编码并翻转 v :

```
Python
# 数据编码（选择编码）
data['response'] = data['choice']

# 构建模型
hddmStim_vflip = hddm.HDDMStimCoding(
    data,
    stim_col = 'stim',
    split_param = 'v',
    include = ['v', 'a', 't', 'z'],
    depends_on = {'z': ['condition'], 'v': ['condition']},
    bias = True
)
```

上述两种代码输出的结果完全一致，翻转后 z 始终表示朝向选项 A 的偏差， v 表示朝向正确选项的证据积累速率。

若研究兴趣在于漂移偏差或希望区分偏差来源，应选择选择编码并翻转 v 参数，并通过 `drift_criterion = True` 估计 dc :

```
Python
# 数据编码（选择编码）
data['response'] = data['choice']

hddmStim_vflip = hddm.HDDMStimCoding(
    data,
    stim_col = 'stim',
    split_param = 'v',
    include = ['v', 'a', 't', 'z'],
    drift_criterion = True, # 拟合 dc
    depends_on = {'z': ['condition'], 'v': ['condition']},
    bias = True
)
```

```
)
```

3.4.2 基于 HDDMRegression 函数的实现

HDDMRegression 是 HDDM 的扩展版本，允许将 DDM 参数表示为回归方程的函数。它不仅能处理分类变量，还能直接将连续变量（如神经信号）纳入模型。其能通过两种方式实现参数翻转：

（1）自定义链接函数（link function）

此方式继承 hddm.HDDMStimCoding()函数的核心思想，通过条件性函数映射实现参数翻转。对于参数 z 的翻转，代码如下：

```
Python
# 翻转 z

# 数据编码（准确性编码）
data['response'] = data['acc']

# 定义链接函数
def z_link_func(x, data):
    stim = data.stim.loc[x.index]
    z_flip = (stim * x) + (1 - x) * (1 - stim)
    return z_flip

# 构建回归模型
z_reg = [{'model': "z ~ 1", 'link_func': z_link_func}]

hddmReg_zflip = hddm.HDDMRegressor(
    data,
    z_reg,
    bias=True,
    include=['v', 'a', 't', 'z'],
    group_only_regressors=False
)
```

对于参数 v 的翻转，代码如下：

```
Python
```

```

# 翻转 v

# 数据编码（选择编码）
data['response'] = data['choice']

# 定义链接函数
def v_link_func(x, data):
    stim = data.stim.loc[x.index]
    v_flip = x.where(stim == 1, -x)
    return v_flip

# 构建回归模型
v_reg = [{'model': "v ~ 1", 'link_func': v_link_func}]

hddmReg_vflip = hddm.HDDMRegressor(
    data,
    v_reg,
    bias=True,
    include=['v', 'a', 't', 'z'],
    group_only_regressors=False
)

```

自定义的链接函数使 z 或 v 在一种刺激条件下保持原值，而在另一种刺激条件下被映射为 $1-z$ 或 $-v$ 。

(2) 将刺激作为回归项纳入模型

若需同时估计 v 与 dc ，可将刺激作为预测变量纳入回归方程。模型形式为：

$$v \sim \beta_0 + \beta_1 \cdot stim \quad (1)$$

当 $stim$ 被编码为 -1 和 1 时，截距 β_0 对应 dc ，斜率 β_1 对应 v ；当 $stim$ 被编码为 0 和 1 时，转换关系为：

$$v = \frac{\beta_1}{2}, dc = \beta_0 + \frac{\beta_1}{2} \quad (2)$$

代码实现如下：

```
Python
# 数据编码（选择编码）
data['response'] = data['choice']

# 回归模型
v_reg = [{ 'model': "v ~ 1 + stim", 'link_func': lambda x: x}]

hddmReg_stim_vflip = hddm.HDDMRegressor(
    data,
    v_reg,
    bias=True,
    include=['v', 'a', 't', 'z'],
    group_only_regressors=False
)
```

一般而言，若实验设计仅为单因素两水平（如刺激类型 A/B），推荐使用 HDDMStimCoding，代码简洁且不易出错。若涉及多因素设计、连续变量（如神经指标）或需控制协变量，则应选用 HDDMRegression，其灵活性可满足更复杂的建模需求。

4 基于模拟数据的检验

为直观展示如何利用 HDDM 捕捉两类决策偏差，本节通过模拟数据演示其建模流程。针对起始点偏差与漂移偏差，我们对比了多种实现路径，涵盖了从数据生成到参数恢复的关键步骤，并阐述了结果的解读方法。本小节代码见 GitHub 仓库（https://github.com/Chuan-Peng-Lab/ddm_stim_coding_posts）的 simulation 文件夹。

4.1 起始点偏差

4.1.1 模拟设计

在起始点偏差的模拟中，使用 HDDM 生成 20 名被试的模拟数据，具体参数设定如下： $a = 1$ ， $t = 0.28$ ， $v = 1$ ， z 在三种偏差条件下分别从如下分布中抽样 $N(0.60, 0.05)$ （偏向上边界）、 $N(0.50, 0.05)$ （无偏）、 $N(0.40, 0.05)$ （偏向下边界）。每个条件生成 300 个试次。图 1 展示了模拟数据的条件反应函数（conditional response function, CRF），该函数通过统计不同时间区间内的反应比例，可评估偏

差随时间变化的动态特征。图中黄色线条显示，起始点偏差条件下，较快反应试次中上边界选择比例显著高于中性条件（灰色线条），且该效应随反应时延长而逐渐减弱。这一模式验证了起始点偏差主要影响决策早期加工的理论预期。




图1 两种偏差模拟数据的条件反应函数。纵坐标为选择上边界选项的比例，横坐标为反应时分布的分位数。起始点偏差主要影响较快反应（图中黄色线条），漂移偏差持续作用于全过程（图中蓝色线条）。

4.1.2 结果分析与解释

为比较不同建模方式对起始点偏差的恢复能力，分别采用 `hddm.HDDM()` 函数，`hddm.HDDMStimCoding()`函数和 `hddm.HDDMRegressor()`函数，并结合不同编码方式对数据进行拟合。共评估 9 种建模组合，具体见表 2。

表 2 起始点偏差 9 种不同建模组合

HDDM 函数	模型代号	编码方式	翻转的参数
HDDM	Base_acc	准确性编码	/
	Base_choice	选择编码	/

HDDMStimCoding	Stim_acc_zflip	准确性编码	翻转 z
	Stim_choice_vflip	选择编码	翻转 v
	Reg_acc	准确性编码	/
	Reg_choice	选择编码	/
HDDMRegression	Reg_acc_zflip	准确性编码	翻转 z
	Reg_choice_vflip_link	选择编码	翻转 v (通过链接函数)
	Reg_choice_vflip_coef	选择编码	翻转 v (通过回归系数)

注：模型代号中，Base、Stim、Reg 分别表示使用 HDDM、HDDMStimCoding、HDDMRegression 函数；acc 和 choice 表示编码方式；zflip 和 vflip 表示翻转的参数；link 和 coef 表示回归模型中实现翻转的方式（通过链接函数或回归系数）；未标注 flip 的模型表示无参数翻转。

拟合结果表明，采用准确性编码的两个模型（Base_acc、Reg_acc）无法恢复设定的起始点偏差（ z 在所有条件下均接近 0.5，见图 2A, E）。采用选择编码但未进行参数翻转的两个模型（Base_choice、Reg_choice）虽能恢复 z 的偏差模式，但导致 v 估计失真（接近 0）。5 种结合基础编码与结合参数翻转的模型（Stim_acc_zflip、Stim_choice_vflip、Reg_acc_zflip、Reg_choice_vflip_link 和 Reg_choice_vflip_coef）均能准确恢复 z 偏差模式，同时提供合理的 v 值估计，并且它们的 DIC（Deviance Information Criterion）值更低（-1920~-1888），表现更优。




图2 起始点偏差参数恢复与模型比较结果

4.2 漂移偏差

4.2.1 模拟设计

针对漂移偏差，同样模拟 20 名被试的数据，每个条件下 300 个试次。设定参数 $a=1$, $t=0.28$, $z=0.5$, $v=1.2$, dc 在三种偏差条件下分别从如下分布中进行抽样： $N(0.30, 0.05)$ （偏向上边界）、 $N(0.00, 0.05)$ （无偏）、 $N(-0.30, 0.05)$ （偏向下边界）。每个条件模拟 300 个试次。图 1 蓝色线条代表漂移偏差的 CRF 曲线，与中性条件相比，漂移偏差下，上边界选择比例在所有反应时区间均稳定升高，与漂移偏差持续影响证据积累过程的特征一致。

4.2.2 结果分析与解释

为评估不同建模方式对 dc 的恢复能力。本研究在模拟分析中纳入三类模型。第一类模型通过不同刺激下 v 值的差异间接估计 dc ，包括准确性编码模型（Base_acc、Reg_acc、Stim_acc_zflip、

Reg_acc_zflip) 以及通过链接函数翻转 v 的选择编码模型 (Reg_choice_vflip_link)。此类模型无法直接估计 dc , 但可通过让 v 随实验条件和刺激类型变化, 并计算同一条件下两种刺激的 v 的差值来间接反映偏差。若此差值能准确恢复设定的 dc , 说明可通过简单相减替代 dc 的直接估计; 否则, 证明直接建模 dc 的必要性。第二类模型通过 v 本身近似反映 dc , 包括采用选择编码但未进行参数翻转的模型 (Base_choice、Reg_choice)。此类模型同样无法直接估计 dc , 但 v 的解释会直接对应到具体选项, 此时正/负漂移率反映对某一选项的相对偏好, 部分研究者可能试图直接通过比较这种相对偏好来近似反映漂移偏差, 因此也被纳入检验。第三类模型则是可直接估计 dc 的模型, 包括采用选择编码并翻转 v 的 HDDMStimCoding 模型 (Stim_choice_vflip) 和通过回归系数实现 v 翻转的 HDDMRegression 模型 (Reg_choice_vflip_coef), 二者均直接拟合 dc 参数。表 3 展现了漂移偏差的 9 种不同建模组合。

表 3 漂移偏差 9 种不同建模组合

HDDM 函数	模型代号	编码方式	翻转的参数	参数设定
HDDM	Base_acc	准确性编码	/	v 随实验条件和刺激变化
	Base_choice	选择编码	/	v 随实验条件变化
HDDMStimCoding	Stim_acc_zflip	准确性编码	翻转 z	v 随实验条件和刺激变化
	Stim_choice_vflip	选择编码	翻转 v	v 和 dc 随实验条件变化
	Reg_acc	准确性编码	/	v 随实验条件和刺激变化
HDDMRegression	Reg_choice	选择编码	/	v 随实验条件变化
	Reg_acc_zflip	准确性编码	翻转 z	v 随实验条件和刺激变化
	Reg_choice_vflip_link	选择编码	翻转 v (通过链接函数)	v 随实验条件和刺激变化
	Reg_choice_vflip_coef	选择编码	翻转 v (通过回归系数)	v 和 dc 随实验条件变化

拟合结果显示, 在 9 种建模方式中, 仅有可直接估计 dc 的两个模型 (Stim_choice_vflip 和 Reg_choice_vflip_coef) 成功恢复了设定的 dc 偏差模式, 相关参数恢复结果见图 3D 与图 3I。将 v 按

照正确或错误反应进行分条件建模的五个模型（Base_acc、Reg_acc、Stim_acc_zflip、Reg_acc_zflip和 Reg_choice_vflip_link）通过不同刺激类型间 v 的差异间接估计 dc ，得到的结果与实际设定的 dc 在趋势上相似，但估计误差较大（见图 3A、C、E、G、H）。将 v 按照具体选项进行建模的两个模型（Base_choice、Reg_choice）通过 v 反映对某一选项的相对选择偏好，以此差异间接估计 dc ，其结果与实际 dc 值也存在偏离（见图 3B、F）。模型比较表明，直接拟合 dc 的模型在模型比较指标 DIC 上表现更优。




图 3 漂移偏差参数恢复与模型比较结果。其中蓝色标题的为能够直接拟合 dc 的两个模型。

5 基于实证数据的再分析

针对两类决策偏差的模拟研究系统比较了以上建模方式的组合。模拟中，起始点偏差设定 z 偏离 0.5（对应真实研究中的刺激概率或先验信息操纵），它在数据上表现为较快反应试次中的选择比

例变化（图 1 黄色曲线）；相比之下，漂移偏差设定 dc 为非零（对应分类标准的改变），表现为所有反应时区间内的稳定偏移（图 1 蓝色曲线）。建模策略上，前者可采用选择编码或参数翻转模型准确恢复，而后者必须直接拟合 dc 参数（`Stim_choice_vflip` 或 `Reg_choice_vflip_coef`），间接模型均存在较大估计误差。为验证这些发现对真实数据的适用性，本文基于 White 与 Poldrack(2014)的实证研究，对其感知辨别任务数据进行了重新分析。在该任务中，被试需判断竖直线段是“大”还是“小”，参照标准为预先呈现的标准线。

研究通过两种实验操纵分别诱导特定决策偏差。在比例操纵任务中，研究者改变了大小线段的试次出现比例（75%:25%、50%:50%、25%:75%）。预期当某一选项的出现频率显著高于另一选项时，个体会形成先验预期，在证据积累开始前就倾向于选择高频选项，对应起始点偏差。在规则操纵任务中，研究者改变了标准线段的长度（40、50、60），从而调整了大与小的分类标准。距离标准越远的刺激越容易判断，当标准线段较短（40）时，会使个体在证据积累过程中形成朝向大反应的恒定偏向；反之，当标准线段较长（60）时，则产生朝向小反应的恒定偏向，对应漂移偏差。

两种实验操纵下数据的 CRF 曲线符合预期：比例操纵带来的起始点偏差主要影响较快反应试次且效应随反应时延长而衰减；规则操纵带来的漂移偏差在所有反应时区间稳定存在（见图 4）。在此基础上，本文使用 HDDM 重新拟合其数据，并系统比较不同建模方式在捕捉两种偏差方面的表现。本小节代码见 GitHub 仓库（https://github.com/Chuan-Peng-Lab/ddm_stim_coding_posts）的 `real_data` 文件夹。




图 4 实证数据的条件反应函数。图中所示比例均相对于无偏条件，即数值大于 0 表示大反应选项的概率更高。

5.1 起始点偏差

5.1.1 数据描述

数据取自 White 与 Poldrack(2014)感知辨别任务中比例操纵部分，表 4 呈现了其中前 5 行数据。该数据集包含 23 名被试的反应时间（RT）和选择（response）。实验中，被试需要在大和小两个选项间进行决策。根据三种长短线段比例条件（75%:25%、50%:50%、25:75%），定义三种偏差水平（数据中的 condition 列）：偏向大（big bias）、无偏（neutral）和偏向小（small bias）。每个被试共完成 24 个组块，每个组块包含 48 个试次，其中前 6 个组块作为练习不纳入后续分析。

表 4 比例操纵任务数据

subj_idx	rt	response	condition	crit	real_stim	stimulus	acc	choice
0	0.77	1	neutral	50	75	1	1	1
0	0.66	0	neutral	50	45	0	1	0
0	0.42	0	neutral	50	25	0	1	0

0	0.68	0	neutral	50	35	0	1	0
0	0.47	0	neutral	50	35	0	1	0
...	...	...	...	...	...	...	...	...

5.1.2 建模方式

分别采用 `hddm.HDDM()`函数, `hddm.HDDMStimCoding()`函数和 `hddm.HDDMRegressor()`函数, 结合准确性编码、选择编码以及不同编码下的参数翻转进行模型拟合, 系统比较不同建模方式下参数估计的合理性与模型的拟合效果。共评估了 9 种建模组合, 与 4.1.1 节所列相同。

5.1.3 结果分析与解释

White 和 Poldrack (2014) 的原始分析表明, 比例操纵主要影响起始点。在其知觉任务中, 偏向大条件下 z (原文为 sp) 为 0.54, 无偏条件下 z 为 0.44, 偏向小条件下 z 为 0.37, 趋势与实验操纵预期一致。

本文采用 HDDM 重新拟合数据, 拟合结果发现 (图 5), 采用准确性编码时, 无论是基础 HDDM (`Base_acc`) 还是 HDDM 回归模型 (`Reg_acc`) 均无法有效建模起始点偏差, 属于无效的建模策略。采用选择编码或基础编码并结合参数翻转时能反映出实验操纵带来的效应 (三种条件下的 z 值分别在 0.6, 0.5 和 0.4 左右)。当采用选择编码时 (`Base_choice`、`Reg_choice`), v 的估计值为 0.13, 代表对大选项的证据积累率, 虽具一定合理性, 但在理论解释上存在局限, 故不作首选推荐。相比之下, 结合参数翻转的 (`Stim_acc_zflip`、`Stim_choice_vflip`、`Reg_acc_zflip`、`Reg_choice_vflip_link` 和 `Reg_choice_vflip_coef`) 5 种模型不仅能恢复 z 的偏差模式, 还使 v 统一代表朝向正确选项的证据积累速率 (估计值在 1.34–1.47 之间), 理论解释性更强。其中, 基于回归并结合 v 翻转的模型 (`Reg_choice_vflip_coef`) 在模型比较中 DIC 值最低, 表现最优, 为最优选择。




图 5 比例操纵任务参数 z 拟合和模型比较结果。图中红色为不可接受模型，橙色为可接受但不推荐模型，蓝色为推荐模型；黑色虚线为 $z = 0.5$ （无偏差基线），红色虚线为 White 和 Poldrack (2014) 报告的结果。

5.2 漂移偏差

5.2.1 数据描述

该分析采用感知辨别任务中规则操纵部分的数据，表 5 呈现了其中前 5 行数据。该数据集包含 21 名被试的反应时间和选择。实验中，被试需要在大和小两个选项间进行决策。根据三种不同中线长度（40、50、60），定义三种偏差水平：偏向大（big bias）、无偏（neutral）和偏向小（small bias）。每个被试共完成 24 个组块，每个组块包含 48 个试次，其中前 6 个组块作为练习不纳入后续分析。

表 5 规则操纵任务数据

[illegible]

表 6 呈现了不同参照标准与刺激长度条件下的正确率，从中可以观察到三个主要模式：（1）正确率随刺激与标准之间差异的减小而降低，符合感知辨别任务的基本特征；（2）在标准为 50 的中性条件下，正确率存在明显不对称，大反应的正确率高于同等距离的小反应，表明被试存在对大刺激的系统性偏向；（3）这种不对称性在标准刺激为小刺激（40）时消失，在标准刺激为更大的刺激（60）时变大，提示偏差效应可能同时受到物理刺激与心理感知间非线性关系的影响。

表 6 规则操纵任务中不同实验条件和刺激条件下的正确率

参照标准长度 (实验条件)	刺激长度					
	25	35	45	55	65	75
40 (big bias)	85.03%	67.84%	64.52%	85.67%	93.96%	96.00%
50 (neutral)	89.30%	79.05%	55.25%	74.32%	91.00%	93.69%
60 (small bias)	92.99%	87.27%	72.19%	49.35%	78.31%	90.45%

5.2.2 建模方式

根据模拟结果，在众多建模方式中，只有引入 dc 的 HDDMStimCoding (Stim_choice_vflip) 和 HDDMRegression 模型 (Reg_choice_vflip_coef) 能够准确且直接地估计漂移偏差，其他模型只能通过间接方式在一定程度上反映偏差趋势。基于此，实证分析重点聚焦这两种可直接估计 dc 的模型，同时也沿用 9 种建模组合进行系统性对比，以验证其他模型的间接估计效果。

针对可直接拟合 dc 的模型，结合数据特征与模型特点进行不同设定。在 HDDMStimCoding 模型中，为与原研究的分析尽可能保持一致，设定 v 随刺激变化（6 种原始刺激作为分类变量）， dc 随实验条件变化。在 HDDMRegression 模型中则将刺激与标准间的距离作为连续变量纳入回归方程，同时令 dc 随实验条件变化。

5.2.3 结果分析与解释

在 White 和 Poldrack (2014) 的结果中，规则操纵主要影响 dc （在其研究中 dc 小于 0 代表偏向大选项，为便于对比，图 6 中将原文中的 dc 乘以-1，转换后正值对应偏向大选项），且偏向大条件下 dc 为负（-0.13），表明证据积累偏向大选项；偏向小条件下 dc 为正（0.10）表明证据积累偏向小

选项；无偏条件下 dc 接近零 (-0.04)。趋势与实验操纵预期一致。

本文采用 HDDM 重新拟合数据，图 6 展示了 9 种建模方式的拟合结果，其表现与模拟分析一致：2 个可直接拟合 dc 的模型 (Stim_choice_vflip, Reg_choice_vflip_coef) DIC 值远低于其余模型。未进行参数翻转的选择编码模型 (Base_choice, Reg_choice) DIC 值均超过 13000，拟合效果较差。基于准确性编码的模型 (Base_acc, Reg_acc, Reg_acc_zflip, Stim_acc_zflip) 与基于链接函数实现漂移率翻转的模型 (Reg_choice_vflip_link)，DIC 值均显著高于直接拟合 dc 的模型。并且所有间接模型拟合出的结果 dc 在三种条件下均大于 0，仅能粗略反映被试整体存在对大选项的固有偏向，无法体现实验操纵带来的效应。

在此重点针对 2 个可直接拟合 dc 的模型，结合行为数据特征展开深入分析。Stim_choice_vflip 模型的拟合结果显示：偏向大条件下 dc 为 0.81，无偏条件下 dc 为 0.39，偏向小条件下 dc 为 -0.13 ；Reg_choice_vflip_coef 模型的拟合结果显示：偏向大条件下 dc 为 0.44，无偏条件下 dc 为 0.30，偏向小条件下 dc 为 -0.03 。二者均呈现出偏向大条件下 dc 显著为正，无偏条件下 dc 为正，偏向小条件下 dc 为负的变化规律，与实验操纵的预期效应一致，与 White 和 Poldrack(2014)的结论基本一致。即，偏向大条件下被试存在朝向大选项的恒定漂移偏差，偏向小条件下被试存在朝向小选项的恒定漂移偏差。同时，无偏条件下的正 dc 值也对应了表 6 中行为数据呈现的被试对大刺激的固有选择偏向。然而，回归模型拟合得到的偏向小条件下的 dc 接近 0，其原因在于回归模型将刺激与标准的实际距离作为预测变量，能够考虑表 6 揭示的物理刺激与心理感知间非线性关系的影响，即偏向小条件下被试原本对大刺激的偏向会更大，从而削弱实验操纵带来的效应。综合拟合结果，Reg_choice_vflip_coef 模型为最优选择。




图 6 规则操纵任务参数 dc 拟合和模型比较结果。图中橙色为间接拟合 dc 的模型，蓝色为直接拟合 dc 的模型；黑色虚线为 $dc = 0$ （无偏差基线），红色虚线为原文报告的结果（ dc 乘以-1）

6 展望与建议

长期以来，决策偏差的计算建模缺乏系统的比较与梳理，尤其在“实验操纵—数据特征—建模策略”的逻辑链条上尚未达成共识：一是缺乏对两类偏差所对应的实验操纵的清晰界定；二是缺乏对不同操纵下数据结构、编码和行为特征的理解；三是缺乏在不同实验情境下，确定决策偏差类型、数据结构与建模策略之间的匹配关系。本文通过模拟与实证分析，系统比较多种建模方案，展示了不同偏差所对应的建模策略，并为研究者提供了从原理到实践的系统指南。本教程所有模拟与实证分析的完整代码可通过以下链接获取：https://github.com/Chuan-Peng-Lab/ddm_stim_coding_posts。

本文以 White 和 Poldrack(2014)的数据为例，演示了如何建模两类偏差。通过改变刺激出现概率诱发的起始点偏差在条件反应函数中表现为较快反应试次的选择比例显著高于较慢反应试次，且该效应随反应时延长而衰减，这与起始点偏差源于决策前的初始偏好，主要影响决策早期阶段的预期一致。相比之下，通过改变标准线段长度诱发的漂移偏差则所产生的选择比例差异贯穿整个反应时分布，体现了漂移偏差对决策过程的持续影响。两类偏差在条件反应函数中呈现出不同的形态，这一特征可用于指导建模策略的选择。研究者可在预分析阶段通过观察条件反应函数的形态初步判断数据中可能存在的偏差类型，从而选择更有针对性的建模方案。

需要说明的是，使用 HDDM 对 dc 的建模与 White 和 Poldrack(2014)的核心结论一致，但并非

完全相同。本文的结果与其行为数据更加契合，在规则操纵任务中更能体现出被试对大选项的系统偏向。这说明规范、系统的建模方式能够使参数估计更真实地反映行为数据。

模拟与实证分析一致表明：不同偏差类型对应不同的建模方式，存在错误、可接受和最优选择之分。起始点偏差可通过选择编码或参数翻转准确恢复，而漂移偏差必须直接拟合 dc 参数才能实现无偏估计。在模型选择层面，基于回归的模型（HDDMRegression）在灵活性方面具有明显优势，适用于多因素实验设计或需纳入连续变量的研究场景。例如，当研究者希望将神经信号作为预测变量纳入模型，回归框架提供了更灵活的操作空间。而在简单设计条件下，HDDMStimCoding 模型兼顾效率与准确性，代码更为简洁，不易出错。

需要注意，两类偏差在建模复杂度上存在不对称性。起始点偏差的建模仅需对起始点参数进行翻转，模型复杂度较低；而漂移偏差的建模需要引入额外的 dc 参数，模型参数更多，有可能更易出现过拟合，研究者应在模型比较时纳入考虑。此外，本文主要聚焦于单一偏差情境下的建模策略。然而在实际研究中，起始点偏差与漂移偏差可能同时存在。针对此类复合偏差情境，采用包含 dc 的模型（HDDMStimCoding 设置 `drift_criterion=True`）或基于回归的翻转模型（HDDMRegression 将刺激作为预测变量）能够同时对两种偏差进行估计。若怀疑数据中同时存在两种偏差，可考虑上述模型。补充材料中提供了这两类模型对复合偏差的拟合结果参考。

综合上述结论，本文建议在实际建模时需：（1）预先明确待研究的偏差类型，明确核心研究目标是任务表现、检验起始点偏差或漂移偏差，还是区分偏差来源；（2）系统比较多种建模方案，对比基础编码（准确性编码或选择编码）与参数翻转编码（翻转 z 或翻转 v ）的拟合结果，结合模型比较与参数估计的合理性（如 v 是否符合理论预期）筛选合适模型；（3）详细报告建模细节和具体的代码以确保透明与可重复性。

参考文献

- 刘逸康, 胡传鹏. (2024). 证据积累模型的行为与认知神经证据. *科学通报*, 69(8), 1068-1081. <https://doi.org/10.1360/tb-2023-1080>
- Ashby, F. G. (1983). A biased random walk model for two choice reaction times. *Journal of Mathematical Psychology*, 27(3), 277-297. [https://doi.org/10.1016/0022-2496\(83\)90011-1](https://doi.org/10.1016/0022-2496(83)90011-1)
- Boag, R. J., Innes, R. J., Stevenson, N., Bahg, G., Busemeyer, J. R., Cox, G. E., Donkin, C., Frank, M. J., Hawkins, G. E., Heathcote, A., Hedge, C., Lerche, V., Lilburn, S. D., Logan, G. D., Matzke, D., Miletic, S., Osth, A. F., Palmeri, T. J., Sederberg, P. B., . . . Forstmann, B. U. (2025). An Expert Guide to Planning Experimental Tasks For Evidence-Accumulation Modeling. *Advances in Methods and Practices in Psychological Science*, 8(2). <https://doi.org/10.1177/25152459251336127>
- Bogacz, R., Brown, E. T., Moehlis, J., Holmes, P., & Cohen, J. D. (2006). The physics of optimal decision making: a formal analysis of models of performance in two-alternative forced-choice tasks. *Psychological Review*, 113 4, 700-765.
- Cerracchio, E., Miletic, S., & Forstmann, B. U. (2023). Modelling decision-making biases. *Frontiers in Computational Neuroscience*, 17. <https://doi.org/10.3389/fncom.2023.1222924>
- Cléry-Melin, M. L., Jollant, F., & Gorwood, P. (2019). Reward systems and cognitions in Major Depressive Disorder. *CNS Spectr*, 24(1), 64-77. <https://doi.org/10.1017/s1092852918001335>
- Diederich, A., & Busemeyer, J. R. (2006). Modeling the effects of payoff on response bias in a perceptual discrimination task: Bound-change, drift-rate-change, or two-stage-processing hypothesis. *Perception & Psychophysics*, 68(2), 194-207. <https://doi.org/10.3758/BF03193669>
- Eshel, N., & Roiser, J. P. (2010). Reward and punishment processing in depression. *Biological Psychiatry*, 68(2), 118-124. <https://doi.org/10.1016/j.biopsych.2010.01.027>
- Gotlib, I. H., & Joormann, J. (2010). Cognition and depression: current status and future directions. *Annual Review of Clinical Psychology*, 6, 285-312. <https://doi.org/10.1146/annurev.clinpsy.121208.131305>
- Horne, S. J., Topp, T. E., & Quigley, L. (2021). Depression and the willingness to expend cognitive and physical effort for rewards: A systematic review. *Clinical Psychology Review*, 88, 102065. <https://doi.org/10.1016/j.cpr.2021.102065>
- Huys, Q. J. M., Daw, N. D., & Dayan, P. (2015). Depression: a decision-theoretic analysis. *Annual review of neuroscience*, 38, 1-23. <https://doi.org/10.1146/annurev-neuro-071714-033928>

- Leite, F. P., & Ratcliff, R. (2011). What cognitive processes drive response biases? A diffusion model analysis. *Judgment and Decision Making*, 6(7), 651-687. <https://doi.org/10.1017/s1930297500002680>
- Leong, Y. C., Hughes, B. L., Wang, Y., & Zaki, J. (2019). Neurocomputational mechanisms underlying motivated seeing. *Nature Human Behaviour*, 3(9), 962-973. <https://doi.org/10.1038/s41562-019-0637-z>
- Liebman, E. (2020). Modeling the Impact of Music on Human Decision-Making. In E. Liebman (Ed.), *Sequential Decision-Making in Musical Intelligence* (pp. 67-88). Springer International Publishing. https://doi.org/10.1007/978-3-030-30519-2_5
- Lloyd, A., Roiser, J. P., Skeen, S., Freeman, Z., Badalova, A., Agunbiade, A., Busakhwe, C., DeFlorio, C., Marcu, A., Pirie, H., Saleh, R., Snyder, T., Fearon, P., & Viding, E. (2024). Reviewing explore/exploit decision-making as a transdiagnostic target for psychosis, depression, and anxiety. *Cognitive, Affective, & Behavioral Neuroscience*, 24(5), 793-815. <https://doi.org/10.3758/s13415-024-01186-9>
- Mulder, M. J., Prummer, F., Terburg, D., & Kenemans, J. L. (2023). Drift–diffusion modeling reveals that masked faces are preconceived as unfriendly. *Scientific reports*, 13(1), 16982. <https://doi.org/10.1038/s41598-023-44162-y>
- Mulder, M. J., Wagenmakers, E.-J., Ratcliff, R., Boekel, W., & Forstmann, B. U. (2012). Bias in the Brain: A Diffusion Model Analysis of Prior Probability and Potential Payoff. *The Journal of Neuroscience*, 32(7), 2335. <https://doi.org/10.1523/JNEUROSCI.4156-11.2012>
- Pan, W., Geng, H., Zhang, L., Fengler, A., Frank, M. J., Zhang, R.-Y., & Chuan-Peng, H. (2025). dockerHDDM: A User-Friendly Environment for Bayesian Hierarchical Drift-Diffusion Modeling. *Advances in Methods and Practices in Psychological Science*, 8(1). <https://doi.org/10.1177/25152459241298700>
- Ratcliff, R., Gomez, P., & McKoon, G. (2004). A Diffusion Model Account of the Lexical Decision Task. *Psychological Review*, 111(1), 159-182. <https://doi.org/10.1037/0033-295x.111.1.159>
- Ratcliff, R., & McKoon, G. (2008). The diffusion decision model: theory and data for two-choice decision tasks. *Neural Computation*, 20(4), 873-922. <https://doi.org/10.1162/neco.2008.12-06-420>
- Ratcliff, R., Smith, P. L., Brown, S. D., & McKoon, G. (2016). Diffusion Decision Model: Current Issues and History. *Trends in Cognitive Sciences*, 20(4), 260-281. <https://doi.org/10.1016/j.tics.2016.01.007>
- Sánchez-Fuenzalida, N., Van Gaal, S., Fleming, S. M., Haaf, J. M., & Fahrenfort, J. J. (2023). Predictions and rewards affect decision-making but not subjective experience. *Proceedings of the National Academy of Sciences*, 120(44), e2220749120.

- Scholz, V., Kandroodi, M. R., Algermissen, J., & Ouden, H. d. (2020). Dissociable Effects of Mood-Anxiety and Compulsive Symptom Dimensions on Motivational Biases in Decision-Making. *Biological Psychiatry*, 87(9), S382-S383. <https://doi.org/10.1016/j.biopsych.2020.02.979>
- Simen, P., Contreras, D., Buck, C., Hu, P., Holmes, P., & Cohen, J. D. (2009). Reward rate optimization in two-alternative decision making: empirical tests of theoretical predictions. *Journal of Experimental Psychology: Human Perception and Performance*, 35(6), 1865-1897. <https://doi.org/10.1037/a0016926>
- Tomkins, B., Perea, M., Virtue, S., & Gomez, P. (2025). Response biases in the divided visual field lexical decision task: A diffusion model account. *Visual Cognition*, 33(3), 198-215. <https://doi.org/10.1080/13506285.2025.2552237>
- Urai, A. E., de Gee, J. W., Tsetsos, K., & Donner, T. H. (2019). Choice history biases subsequent evidence accumulation. *eLife*, 8, e46331. <https://doi.org/10.7554/eLife.46331>
- van Ravenzwaaij, D., Mulder, M., Tuerlinckx, F., & Wagenmakers, E.-J. (2012). Do the Dynamics of Prior Information Depend on Task Context? An Analysis of Optimal Performance and an Empirical Test. *Frontiers in Psychology*, 3, 132. <https://doi.org/10.3389/fpsyg.2012.00132>
- Voss, A., Nagler, M., & Lerche, V. (2013). Diffusion models in experimental psychology: a practical introduction. *Experimental Psychology*, 60(6), 385-402. <https://doi.org/10.1027/1618-3169/a000218>
- White, C. N., Liebman, E., & Stone, P. (2017). Decision mechanisms underlying mood-congruent emotional classification. *Cognition and Emotion*, 32(2), 249-258. <https://doi.org/10.1080/02699931.2017.1296820>
- White, C. N., & Poldrack, R. A. (2014). Decomposing bias in different types of simple decisions. *Journal of experimental psychology. Learning, memory, and cognition*, 40(2), 385-398. <https://doi.org/10.1037/a0034851>
- White, C. N., Ratcliff, R., Vasey, M. W., & McKoon, G. (2010). Using diffusion models to understand clinical disorders. *Journal of Mathematical Psychology*, 54(1), 39-52. <https://doi.org/10.1016/j.jmp.2010.01.004>
- Wiecki, T. V., Sofer, I., & Frank, M. J. (2013). HDDM: Hierarchical Bayesian estimation of the Drift-Diffusion Model in Python. *Frontiers in Neuroinformatics*, 7, 14. <https://doi.org/10.3389/fninf.2013.00014>

补充材料

复合偏差的模型拟合

模拟设计

复合偏差数据包含以下三种条件：（1）无偏差（ $z = 0.5$ ， $dc = 0$ ）；（2）起始点偏差和漂移偏差方向相同（ $z = 0.6$ ， $dc = 0.3$ ）；（3）起始点偏差和漂移偏差方向相反（ $z = 0.6$ ， $dc = -0.3$ ）。模拟 20 名被试的数据，每个条件下 300 个试次。

采用包含 dc 的 HDDMStimCoding 模型（设置 `drift_criterion=True`）和基于回归的翻转模型（HDDMRegression 将刺激作为预测变量）对数据进行拟合。

结果

图 S1 展示了两种模型在复合偏差条件下拟合的 z 与拟合的 dc 之间的关系。从图中可以看出：在无偏差条件下（黄色点），拟合的 z 集中在 0.5 附近，拟合的 dc 集中在 0 附近；在同向偏差条件下（红色点），拟合的 z 与拟合的 dc 均呈现正向偏移（ $z \approx 0.6$ ， $dc \approx 0.3$ ）；在反向偏差条件下（蓝色点），拟合的 z 仍呈现正向偏移（ $z \approx 0.6$ ），而拟合的 dc 呈现负向偏移（ $dc \approx -0.3$ ）。上述结果表明，HDDMStimCoding 与 HDDMRegression 模型均能有效区分起始点偏差与漂移偏差，且在两种偏差共存时能够准确恢复两类参数。




图 S1 复合偏差参数恢复结果