

项目路线图：基于高斯过程的实验设计优化

Self-Matching Task (Sui et al., 2012) 框架下，使用漂移扩散模型 (DDM) + 高斯过程 (GP) 优化实验设计参数(P, T, W)，最大化自我优势效应 (SPE) 的捕捉精度。

Phase 0：项目初始化与基线建立

0.1 实验数据采集 已完成

- 采集 8 组真实被试数据（共 88 名被试）
- 实验设计空间 $\Omega = (P, T, W, M)$ ，其中 $M = T + W$
- 8 组实验条件覆盖不同参数水平：

组别	P (练习次数)	T (刺激呈现, ms)	W (反应窗口, ms)	M (最大允许时间, ms)	被试数
G1	0	30	300	330	11
G2	0	30	600	630	12
G3	120	30	600	630	10
G4	120	80	600	680	11
G5	8	100	1100	1200	11
G6	120	500	1500	2000	10
G7	120	30*	800	880	12
G8	120	80	800	880	11

 *G7 的 T 值存在元数据与行为数据不一致问题（元数据标记为 T=30ms，但原始数据实际 T=80ms），详见 Phase 3.2。

0.2 基线 Sigmoid+DDM 生成模型 已完成

- 文件：1_Code/Python_for_Generate/Generate_Data_v1.ipynb、S2 gen_data_jh.ipynb
- 核心函数：
 - compute_v_s2(T, P, condition_key) — 漂移率 v 的 Sigmoid 参数化
 - compute_a_s2(M) — 决策边界 a 的 Sigmoid 参数化
 - v_P_Function(P) — 练习效应对 v 的非线性调制
- 默认参数： $\alpha_1=1.5$, $\alpha_2=-0.4$, $\beta_1=0.2$, $\beta_2=0.0$, $\gamma=0.2$

0.3 生成模型迭代（v2.x 系列） 已完成

- 文件：Generate_Data_v2.1-2.4.ipynb
- 稳定版本：Generate_Data_v2.4_runner.py
- v2.4 特点：Sigmoid + GP 混合方式（GP 在数据生成层面， $w=0.5$ 加权）
- 参数恢复检验：Generate_Data_v2.4_recovery.py

0.4 Sigmoid 参数全表与可优化性分析 已完成

Sigmoid 生成模型由 compute_v() 和 compute_a() 两个核心函数构成（定义于 [S2 gen_data_jh.ipynb](1_Code/Python_for_Generate/S2 gen_data_jh.ipynb)）。以下列出**所有参数**——包括显式定义的变量和隐式硬编码的数字：

A. 显式定义的参数（原代码中直接赋值的变量）

参数	原始默认值	所在函数	含义
alph1	1.5	compute_v()	self 条件增强倍数 ： $v_{self} = v_0 \times (1 + \alpha_1)$
alph2	-0.4	compute_v()	stranger 条件调制倍数 ： $v_{stranger} = v_0 \times (1 + \alpha_2)$
beta1	0.2	compute_a()	高 M 边界增强 ：当 $M > 600$ 时 $a = a_0 \times (1 + \beta_1)$
beta2	0.0	compute_a()	低 M 边界调制 ：当 $M \leq 600$ 时 $a = a_0 \times (1 + \beta_2)$
gamma	0.2	v_P_Function()	练习效应 Sigmoid 陡峭度 ：控制 P 对 $k(P)$ 的调制速率

t0	0.2	generate_data()	非决策时间 Non-decision time（秒）
----	-----	-----------------	----------------------------

B. 隐性/硬编码参数（写在公式内部、未提取为变量的数字）

参数	硬编码值	所在函数/公式	含义
T_0	100	<code>1/(1+exp(-k_T*(T-T_0)))</code>	v-T Sigmoid 中点 (ms) : T=100ms 时 v_T=0.5
k_T	0.01	<code>compute_v()</code>	v-T Sigmoid 陡峭度 : 决定 T 对 v 的影响敏感度
M_0	600	<code>1/(1+exp(-k*(M-M_0)))</code>	a-M Sigmoid 中点 (ms) : M=600ms 时 a_0=base_scale_a/2
k_a	0.01	<code>compute_a()</code>	a-M Sigmoid 陡峭度 : 决定 M 对 a 的影响敏感度
P1	4	<code>v_P_Function()</code>	练习阈值 : P 的最小有效练习量
k_min	0.1	<code>v_P_Function()</code>	练习斜率最小值
k_max	0.05	<code>v_P_Function()</code>	练习斜率最大值 （注意：原始 S2 的 k_P() 定义为 0.01/0.15，但 <code>v_P_Function()</code> 调用时传入 0.1/0.05）
P0	32	<code>v_P_Function()</code>	练习效应 Sigmoid 中点 : P=32 时斜率过渡
base_scale_v	3	<code>compute_v()</code> 中 <code>v_0 = v_T * v_P * 3</code>	v 幅度缩放因子 （隐式，直接写 * 3）
base_scale_a	3	<code>compute_a()</code> 中 <code>a_0 = sigmoid(...) * 3</code>	a 幅度缩放因子 （隐式，直接写 * 3）

C. 可优化性判断

参数	可优化?	是否已优化	理由
----	------	-------	----

alaph1, alaph2	✓	✓ 已优化	核心理论参数，直接编码 self vs stranger 的 DDM 差异
beta1, beta2	✓	✓ 已优化	控制 M（总可用时间）对决策边界的非线性调制
gamma	✓	✓ 已优化	练习效应速率，P 只有 3 水平（0,8,120）时信息有限
base_scale_v	✓	✓ 已优化	原为隐性魔法数字 3，校准代码将其提升为可优化参数
base_scale_a	✓	✓ 已优化	同上，原为隐性魔法数字 3
T_0, k_T	●	可选未做	控制 T→v 敏感度，8 点不足以额外校准
M_0, k_a	●	可选未做	控制 M→a 敏感度，8 点不足以额外校准
P1, k_min, k_max, P0	●	可选未做	P 仅 3 水平，不足以校准 4 个练习效应参数
t0	✗	—	t 是组间差异大的 DDM 参数（0.26~0.66s），不应由 Sigmoid 解释

💡 **关键发现：** base_scale_v 和 base_scale_a 在原始 S2 代码中**确实存在**，只是以隐式方式（* 3）出现。校准代码将它们提取为显式可调参数，使得 Sigmoid 能够缩放适配真实数据的量级。

Phase 1: GP 角色定位与方法论确立 ✓ 已完成

1.1 GP 的三种可能角色分析 ✓ 已完成

经过对 v1、v2.4、v3 三个版本的对比分析，明确了 GP 在框架中的三种可能定位：

角色	描述	对应版本	评估
----	----	------	----

A) 代理模型	GP 替代 Sigmoid，直接学习 (P,T,W) → DDM参数的映射	v1 (GP on anchors)	清晰但理论先验弱
B) 数据层混合	Sigmoid + GP 加权平均生成 RT/ACC (w=0.5)	v2.4	有拟合风险
C) 残差捕捉	Sigmoid 提供理论先验，GP 学习 Sigmoid→真实DDM参数 的残差	当前方案	推荐 

1.2 最终决策：分层验证策略 已完成

Sigmoid 理论先验（校准后）
+
GP 捕捉残差（DDM参数层面）
=
GPSigmoidHybridModel
↓
交叉验证（LOCV）：Leave-One-Condition-Out
↓
外部验证（新实验条件的行为/参数双层面验证）

Phase 2: HDDM 真实数据参数提取 已完成

2.1 HDDM 数据预处理 已完成

- 文件： 1_Code/Python_HDDM/step1_prepare_data.py
- 输入： 2_Data/Real_Data/UnExtact/raw/EXP_data_group*.csv (88 个原始数据文件)
- 输出： 2_Data/Real_Data/HDDM_Ready/hddm_data_group*.csv (8 组 HDDM-ready 数据)
- 处理逻辑：
 - 仅保留 stage='formal' 的实验试次
 - 仅保留 Matching 试次： (circle,self) | (square,stranger)
 - NA 试次标记为 omission=1，RT 设置为 T+W（右截尾）
 - 检验模型列： subj_idx, rt, response, identity, omission

2.2 Docker HDDM 分层模型拟合 已完成

- 文件: 1_Code/Python_HDDM/step2_hddm_fit.py
- 拟合环境: Docker hcp4715/hddm
- 模型规格:
 - 分层贝叶斯 DDM (Hierarchical DDM)
 - depends_on={"v": "identity"} — v 依赖 identity (self vs stranger)
 - MCMC: 3000 samples, 500 burn-in, p_outlier=0.05
 - 每组独立拟合
- 输出: 2_Data/Real_Data/HDDM_Traces/hddm_data_group*_traces.npz 和 *_stats.csv

2.3 参数提取与整合 已完成

- 文件: 1_Code/Python_HDDM/step3_extract_params.py
- 输出: 2_Data/Real_Data/HDDM_Traces/all_groups_ddm_params.csv
- 关键发现:

组别	v_self	v_stranger	SPE_v	a	t(s)	z	遗漏率%
G1	-3.39	-3.36	-0.02	2.01	0.263	0.749	72.3% 
G2	-2.53	-2.62	+0.09	1.18	0.436	0.553	52.4% 
G3	-1.89	-1.73	-0.16	1.22	0.348	0.565	38.6%
G4	+0.64	-0.02	+0.66	1.42	0.353	0.571	38.4%
G5	+1.35	+0.64	+0.71	1.34	0.398	0.452	10.9%
G6	+1.81	+1.17	+0.65	1.48	0.663	0.714	5.6%
G7	+1.20	+0.75	+0.45	1.09	0.405	0.497	14.3%
G8	+2.81	+2.55	+0.26	2.42	0.352	0.498	14.7%

Phase 3: GP+Sigmoid 混合模型构建与验证

3.1 Sigmoid 参数校准 已完成

- 两个版本:

- GP_Sigmoid/sigmoid_calibration.py — **初版**，使用 HDDM 原始参数文件
- GP_Sigmoid_Cleaned/ (内含) — **Cleaned 版**，纠正元数据后重新校准
- **方法**：差分进化算法（Differential Evolution）最小化 Sigmoid 预测 vs HDDM 真实参数的 RMSE
- **校准对象**：alaph1, alaph2, beta1, beta2, gamma, base_scale_v, base_scale_a (7个参数)

两版校准结果对比：

参数	初版 (GP_Sigmoid)	Cleaned版 (GP_Sigmoid_Cleaned)	默认值
alaph1 (self增强)	0.549	0.199	1.5
alaph2 (stranger调制)	-0.220	-0.404	-0.4
beta1 (高M边界)	-0.827	-0.826	0.2
beta2 (低M边界)	1.000	1.000	0.0
gamma (练习效应)	0.701	0.640	0.2
base_scale_v	1.026	1.326	3.0
base_scale_a	10.000	10.000	3.0
最终RMSE	1.614	1.617	—

⚠️ 校准后 alaph1 远小于默认值（0.2 vs 1.5），说明真实数据中 self 的相对增强远小于初始假设。base_scale_a 触及上界（10.0），提示 a 的 Sigmoid 参数化可能需要重新考虑。

3.2 数据清洗与元数据纠正 ⚠️ 进行中

- **发现的问题：**
 1. **G7 元数据不一致**：行为数据 T=30ms，但原始文件和文件名中 T=80ms — **需确认实际采集参数**
 2. **G1-G2 高遗漏率**：遗漏率 >50%，HDDM 参数估计可靠性存疑
 3. **G7-G8 设计重复**：两者均为 (P=120, T=80, W=800)，但得到不同的 DDM 参数（G7: SPE=0.45, G8: SPE=0.26） — 可能反映被试间变异
- **敏感性分析**：已生成多种排除策略的数据表（step2_sensitivity_*.csv）

3.3 GP+Sigmoid 混合模型训练 已完成

- 模型文件: 1_Code/Python_HDDM/GP+Sigmoid/gp_sigmoid_hybrid_model.py
- 核心架构: GPSigmoidHybridModel
 - 对 5 个 DDM 参数 (v_self, v_stranger, a, t, z) 各训练一个独立 GP
 - GP 学习 真实HDDM参数 - Sigmoid预测值 的残差
 - 最终预测 = Sigmoid预测 + GP残差预测
- GP 核函数: ConstantKernel $\times$ RBF + WhiteKernel

3.4 模型交叉验证 初步完成, 需关注结果

训练集拟合 (in-sample):

目标	RMSE	r
v_self	~0	~1.00
v_stranger	~0	~1.00
a	0.208	0.900
t	0.008	0.998
z	~0	~1.00
SPE_v	~0	~1.00

LOCV (Leave-One-Condition-Out):

目标	RMSE	r
v_self	2.21	-0.09 
v_stranger	1.89	0.19
a	0.88	-0.44 
t	0.14	-0.31 
z	0.19	-0.54 
SPE_v	0.72	-0.09 

⚠️ **关键警示：** LOCV 中 DDM 参数层面的交叉验证表现很差（负相关占多数），**但仅有 8 个训练点**，这使得 LOCV 极其不稳定。结论：8 个条件不足以支持 GP 的有效泛化，必须增加实验条件。

3.5 行为层面验证 ✅ 已完成

尽管 DDM 参数层面的 LOCV 不理想，行为层面的模拟验证表现出色：

指标	层面	RMSE	r
Accuracy	identity	0.153	0.968 ✅
Omission Rate	identity	0.145	0.923 ✅
Correct RT Mean	identity	66.8 ms	0.981 ✅
SPE RT	condition	21.1 ms	0.843 ✅

✅ **积极信号：** 行为层面验证效果良好，说明 GP+Sigmoid 模型**在行为重建层面是有效的**，即使 DDM 参数层面的 GP 泛化受限于数据量。

3.6 关键发现与参数解读

3.6.1 Sigmoid 校准参数解读

参数	默认值	Cleaned版最优	变化方向	心理学解释
alaph1	1.5	0.199	⬇️ 大降	self 对 v 的相对增强远小于初始假设。原假设 $v_self = 2.5 \times v_0$ ，实际仅需 $v_self = 1.2 \times v_0$
alaph2	-0.4	-0.404	≈ 几乎不变	stranger 的调制量级与理论预期一致
beta1	+0.2	-0.826	🔴 方向反转	高 M 条件下决策边界 反而降低 ($a = a_0 \times 0.174$)，与原假设相反

beta2	0.0	1.000	● 触达上界	低 M 条件下 $a = a_0 \times 2$ ，被试在短时间窗口中需要更大边界——可能反映了 speed-accuracy tradeoff
gamma	0.2	0.640	⬆ 增加	练习效应比预期更陡峭，从"几乎无练习效应"变为"中等练习效应"
base_scale_v	3.0	1.326	⬇ 下降	v 的整体量级远小于原假设（原假设 v7.5 级别 vs 真实数据 v1-3 级别）
base_scale_a	3.0	10.000	● 触达上界！	a 的 Sigmoid 参数化无法产生足够大的边界值来匹配 G8 ($a=2.42$)

3.6.2 需要解决的模型问题

问题	严重程度	建议
base_scale_a 触及上界	● 高	将搜索上界从 10.0 放宽到 20.0 或 25.0，或重新考虑 a 的函数形式（如使用线性或二次函数替代 Sigmoid）
beta1 符号反转	● 中	检查是否存在数据问题（G7/G8 设计重复导致 a 值被聚合扭曲），或考虑分阶段函数形式
beta2 触及上界	● 中	可能需要为低 M 条件单独建模，或采用不同的边界参数化
仅有 8 个条件	● 高	核心瓶颈。LOCV 中 r 普遍为负，8 个 3D 点不足以支持 GP 泛化
G7 元数据不一致	● 中	元数据 T=30ms vs 数据 T=80ms，需确认实际采集参数
G1-G3 v 负值异常	● 中	高遗漏率（38-72%）导致 HDDM 参数估计不可靠，考虑排除

3.6.3 行为层面验证：积极信号

尽管 DDM 参数层面的 LOCV 表现差（仅 8 点），Sigmoid 理论先验保证了行为层面的稳健重建：

指标	r	RMSE	含义
Correct RT	0.981	66.8 ms	反应时均值几乎完美重建
Accuracy	0.968	0.153	正确率高度一致
Omission Rate	0.923	0.145	遗漏率模式正确捕捉

SPE RT	0.843	21.1 ms	自我优势效应可被模型近似重建
--------	-------	---------	----------------

这验证了方法论的核心假设：**Sigmoid 理论先验 + GP 残差捕捉** 在行为重建层面是有效的，即使 DDM 参数层面的 GP 泛化受限于数据量。

Phase 4：实验设计优化与候选点推荐 ⚠️ 初步完成

4.1 基于不确定性的候选实验点 ✅ 已完成

- 方法：计算 GP 在新设计点的预测不确定性 → 选最高不确定性 top-20 → 排除已有设计点的邻近区域
- 输出： `step6_candidate_design_points.csv` (20 个推荐新实验条件)
- 不确定性分解：

rank	P	T	W	v_self_std	v_stranger_std	a_std	t_std	z_std
1	35	500	300	2.09	2.03	0.45	0.13	0.13

- 主要不确定性来源：v_self 和 v_stranger（各约 2.1），远大于 a/t/z
- 最高不确定性区域：T=500ms, W=300ms 附近（低 W + 高 T 的组合）

4.2 下一轮实验设计建议 📋 待执行

推荐的优先实验条件：

- T=500ms, W=300ms, P=15~45 — 高不确定性区域，填补设计空间
- 解决 G7/G8 重复设计问题 — 区分或合并
- 新增中间 P 水平：P=30, P=60（当前仅有 P=0, 8, 120）

Phase 5：模型应用与最终产出 📋 待执行

5.1 剩余问题处理

- ✅ G7 元数据确认：确认 T 的真实值是 30ms 还是 80ms
- ❑ G1/G2 数据质量评估：是否需要从建模中排除高遗漏组
- ❑ 文献调研：DDM 参数取值范围的心理/统计合理性评估

☐ 模型稳健性检验：增加数据量后重新 LOCV

5.2 论文结构规划（建议）

1. **Introduction**：SMT 范式 + DDM + 实验设计优化的必要性

2. **Methods**：

- 2.1 8 组实验设计空间
- 2.2 Sigmoid 理论参数化（Sigmoid v/a functions）
- 2.3 GP+Sigmoid 混合模型（GP residual capture）
- 2.4 验证策略（LOCV + 外部新数据）

3. **Results**：

- HDDM 提取的真实 DDM 参数模式
- GP+Sigmoid 模型拟合与 LOCV
- 行为层面验证
- 候选实验设计点推荐

4. **Discussion**：

- GP 方法的优势与局限（小样本问题）
- 与 Sui et al. (2012) 的对比
- 实验设计优化的实际指导意义

5.3 关键文献参考

主题	关键文献
SMT 范式	Sui, J., He, X., & Humphreys, G. W. (2012). Perceptual effects of self-prioritization. <i>JEP:HPP</i> , 38(5), 1105-1114.
DDM 参数范围	Ratcliff, R., & McKoon, G. (2008). The diffusion decision model. <i>Neural Computation</i> , 20(4), 873-922.
GP in Psychology	Schulz, E., Speekenbrink, M., & Krause, A. (2018). A tutorial on GP regression. <i>JMP</i> , 85, 1-16.
实验设计优化	Myung, J. I., Cavagnaro, D. R., & Pitt, M. A. (2013). Optimal experimental design. <i>JMP</i> , 57(3), 202-217.



项目总体进度

Phase	内容	状态
Phase 0	实验数据采集 + 基线模型	✅ 已完成
Phase 1	GP 角色定位	✅ 已完成
Phase 2	HDDM 参数提取	✅ 已完成
Phase 3	GP+Sigmoid 建模 + 验证	✅ 初步完成 (⚠️ 8点不足)
Phase 4	候选点推荐 + 下一轮实验	📋 待执行
Phase 5	论文撰写与产出	📋 待执行

当前最大瓶颈

仅有 8 个设计条件是项目当前面临的核心限制。GP 在 8 个点上无法有效泛化（LOCV 失败），需要在 Phase 4 中至少新增 4-6 个实验条件。